AIニュース日次レポート - 2026-10-26

Daily AI news report for ぬし / Reptile Environment OS

対象日: 2026-10-26

1. Microsoft Research: ワークフロー評価を壊れ方の深刻度で校正する WorkflowPerturb

- **概要:** Microsoft Researchは10月25日、複数エージェントが作る手順の評価指標を検証するベンチマーク「WorkflowPerturb」を公開しました。4,973件の正解ワークフローから、手順の欠落、圧縮、説明変更を10・30・50%の深刻度で加えた44,757件の変種を作り、評価指標が劣化の大きさを適切に反映するかを比較します。データセットは論文採択後に公開予定です。
- **なぜ重要か:** エージェントの出力を単一スコアで採点しても、その差が軽微な表現変更なのか、実行不能につながる工程欠落なのかは分かりません。意図的な故障を段階的に注入することで、評価指標そのものの感度と校正を検査する枠組みになります。
- **ぬし・爬虫類への使い道:** 飼育記録や点検手順をAIに整理させる場合、「表現が短くなった」「確認工程が消えた」「警告条件が変わった」を別々に試し、危険な欠落を強く減点できるか確認できます。加温・照明などの実制御はAI評価だけに任せず、固定ルールと人の確認を残します。
- **リンク:** https://www.microsoft.com/en-us/research/publication/workflowperturb-calibrated-stress-tests-for-evaluating-multi-agent-workflow-metrics/

2. Microsoft Research: 既存インデックスを作り直さず会話検索を強化する RCEM

- **概要:** Microsoft Researchは10月25日、会話検索向け埋め込みモデル「RCEM」を公開しました。長い会話を文書へ直接対応させる代わりに、LLMが書き換えた検索クエリへ会話表現を整合させ、元の埋め込み空間を保ちます。既存インデックスを再構築せず利用でき、分布が変わる条件では従来法より最大30%改善したと報告しています。
- **なぜ重要か:** 会話履歴から過去の情報を探す際、検索モデルを更新するたびに全データを再埋め込みする費用を抑えながら、言い換えへの耐性を上げる方法です。ただし最大値は実験条件に依存し、実データでの誤検索や取りこぼしは別途測る必要があります。
- **ぬし・爬虫類への使い道:** 「昨日の餌の量」「前に似た温度低下があった日」のような会話的な質問から飼育ログを探す用途に合います。検索結果には元記録と日時を必ず表示し、健康判断や機器操作は検索結果だけで自動決定しません。
- **リンク:** https://www.microsoft.com/en-us/research/publication/rcem-robust-conversational-search-embedder-in-distributional-shift/

3. Google Research: EMNLP 2026で31本の論文と文化的知能評価を紹介

- **概要:** Google Researchは10月24日から29日のEMNLP 2026で、31本の採択論文、11件のワークショップ、2件のチュートリアルを紹介しています。10月25日の展示では、実利用の質問に対する文化的知能と失敗を測るダッシュボードを実演し、言語モデル、マルチモーダル理解、エージェント、安全な展開を幅広く扱います。
- **なぜ重要か:** 多言語AIの品質は翻訳精度だけでなく、地域固有の知識、価値観、利用状況での失敗を測れるかに左右されます。評価を抽象的な平均点から、実際の質問と失敗例を追える指標へ近づける動きです。
- **ぬし・爬虫類への使い道:** 日本語の飼育用語、製品名、季節表現を含む質問セットを作り、英語中心の評価では見えない誤解を記録できます。AIの説明は参考情報として出典を添え、種別の飼育判断は一次資料や専門家へ確認します。
- **リンク:** https://research.google/conferences-and-events/google-at-emnlp-2026/

ユグ的に今日いちばん気になるもの

今日いちばん気になるのは、**WorkflowPerturbが評価指標そのものを段階的な故障で試すこと**です。エージェントが「だいたい合っている」だけでは、重要な確認工程の欠落を見逃します。ぬしの仕組みでも、安全に関わる手順を意図的に少しずつ壊したテストを用意し、危険な欠落を確実に検知できるかを先に確かめたいです。🦎

Generated by ユグ 🦎 from memory/ai-news/2026-10-26.md