

AIニュース週間サマリー - 2026-09-26

Weekly AI news summary for めし / Reptile Environment OS

対象期間: 2026-09-20～2026-09-26

入力レポート

- 2026-09-20, 2026-09-21, 2026-09-22, 2026-09-23, 2026-09-24, 2026-09-25, 2026-09-26 の日次7本
- 復旧前は2026-09-25と2026-09-26が欠落していたため、一次情報の公開日を再確認して今回補完した。入力時点の不足日はなし。

今週の大きな流れ

1. モデル移行は名前の置換ではなく、評価と停止条件の更新になった

GPT-5.5の終了予定、Solへの移行、GitHubでのGPT-6 Sol/LunaとClaude Opus 5.5の用途別提供、Sonnet 5.5の速度・費用差が並びました。モデル更新は出力品質だけでなく、ツール経路、費用、待ち時間、失敗分布を変えます。自動フォールバックで境界を広げず、固定入力の回帰試験を通してから役割ごとに切り替える必要があります。

2. エージェント安全は外部評価・共通測定・Safety Caseへ進んだ

独立評価者を開発現場へ組み込む試み、共通測定基準、監査制度、プロジェクト別サンドボックス、管理設定の検証器が続きました。安全は単一ベンチマークではなく、主張、証拠、設定、未解決点、停止条件を結ぶ運用文書と、モデル外の強制層で支える方向です。

3. 記憶・通信・観測が長時間エージェントの主要リスクになった

Copilot Memoryを使う修正、OpenTelemetryによるツール追跡、第三者サービスへのデータ送信事例、長時間Autopilotが同じ週に現れました。記憶や継続実行を便利にするほど、どの情報を再利用したか、どこへ送ったか、誰の権限で動いたかを追跡する必要があります。

4. AIの科学利用は仮説生成から現実の検証へつながった

Claudeによる酵素系候補探索は、既知結果の再現、候補の批判的絞り込み、人による確認、実験室検証を分けました。AIが大量に仮説を出せても、それ自体を発見や事実と扱わず、反証可能な実験へ渡す設計が重要です。

5. 小型化と運用効率は、信用割当と資源観測まで含む話になった

REOPOLDは教師信号を選択的に割り当て、Hugging Face JobsはCPU・GPU・メモリをライブ表示しました。軽量化はモデルサイズだけでなく、何を学習へ反映し、実行時に資源を使い過ぎていないかまで観測する必要があります。

ユグ的に気になるもの特集

今週いちばん気になるのは、**モデル、記憶、権限、通信、資源**を別々の昇格条件で管理することです。

1. 日常要約、原因候補、設定提案、実操作を別の能力IDにする。
2. モデル更新前後で同じログを再生し、出典、停止、費用、処理時間を比較する。
3. 記憶には出所、対象個体・設備、有効期限を付ける。
4. 外向き通信は許可先と送信項目を固定し、検査不能なら閉じる。
5. 実操作はSafety Caseと人の承認、独立安全層が揃うまで開放しない。

ぬし向け実験候補

- 既存の温湿度ログ1日分を固定入力にし、現行モデルと候補モデルで「事実・推定・提案」の混在率を比較する。
- 記憶検索結果へ個体ID、設備ID、取得日を表示し、別ページの記憶が混ざったら失敗にする。
- AI処理のCPU・メモリ・所要時間を記録し、センサー収集を遅らせる負荷で自動停止する。

来週も追いたいこと

- Safety Caseを家庭内自動化の小さな変更へ適用できるテンプレート
- 記憶の出所・期限・削除を含む評価方法
- サンドボックス外通信をモデル外で遮断する実装
- モデル更新時のツール経路と費用の回帰試験

Generated by ユグ  from memory/ai-news-weekly/2026-09-26.md